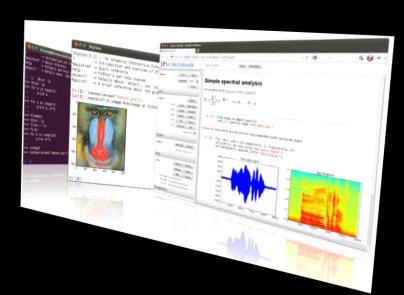


# Python 数据分析

梁斌 2016年10月30日



#### 什么是"数据"?

- 结构化数据(structured data),如:
  - 多维数组 (矩阵)
  - 表格型数据, 其中各列可能是不同的类型(字符串、数值、日期等)。
  - 等等
- 原始数据
  - 可以被转化为更加适合分析和建模的结构化形式,即结构化数据。
  - 或者将原始数据的特征提取为某种结构化形式,例如,一组新闻文章可以被转化为词频表,从而用于情感分析。

#### 工欲善其事必先利其"器"

- 电子表格软件
  - Microsoft Excel
  - OpenOffice Spreadsheet 等

#### Python

- 近几年非常流行的脚本(scripting)语言,用于编写简短而"粗糙"的小程序(即脚本)。
- 拥有一个巨大而活跃的科学计算(scientific computing)社区。
- 在行业应用和学术研究中采用Python进行科学计算的势头越来越猛。
- 在数据分析和交互、探索性计算以及数据可视化等方面,Python将不可避免地接近于其他开源和商业的领域特定编程语言/工具,如R、Matlab等。

### Python 特点

- Python有不断改良的库(主要是pandas)。
- 在通用编程方面有强大实力。
- 完全可以只使用Python这一种语言去构建以数据为中心的应用程序。
- Python不仅适用于研究和原型构建,同时也使用于构建生态系统。
- Python是一种解释型编程语言,比用编译型语言编写的代码运行慢。
- 不适合高并发、多线程的应用程序。

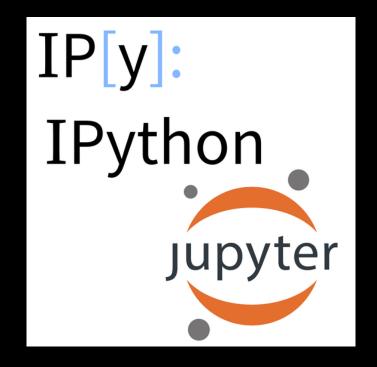


# 编程环境

- PyCharm
- Eclipse + PyDev
- IPython
- Jupyter notebook







## 重要的Python库

- Numpy (Numerical Python), Python科学计算的基础包。
- SciPy (Scientific Python),一款方便、易于使用、转为科学和工程设计的Python工具包。
- Matplotlib,Python著名的绘图库。
- Pandas (Python Data Analysis Library),基于Numpy构建的含有更高级数据结构和工具的数据分析包。
- Scikit Learn,基于Python的机器学习模块。

#### 案例讲解

- 1880-2014年间全美婴儿姓名分析
- Kaggle US Baby Names项目提供了一份从1880年到2014年的婴儿名字数据。
- 利用这个数据集可以进行:
  - 计算指定姓名的年度比例
  - 计算某个姓名的相对排名
  - 计算各年度最流行的姓名,以及增长或减少最快的姓名
  - 分析姓名趋势: 长度、元音、辅音等

#### 代码讲解

- 数据概述
- 美剧对婴儿姓名的影响

